

Matriz de Optimización de Costos

Ecosistema de Automatización IA — Clínica Médica

1. Criterio general

El costo de un modelo de IA no es un número aislado: hay que evaluarlo contra la complejidad real de cada tarea. Usar el modelo más caro en todos los nodos desperdicia presupuesto; usar el más barato en todos los nodos degrada la calidad donde sí importa. Este ecosistema asigna el modelo según dos ejes: **complejidad de la tarea** (extracción simple vs. redacción con contexto) y **urgencia** (tiempo real vs. procesamiento diferido).

2. Modelo asignado por tarea

Tarea	Modelo usado	Precio (input/output por 1M tokens)	Por qué este modelo
Extracción de intención (Proceso A — Agendamiento)	GPT-4.1-mini	\$0.40 / \$1.60	Tarea simple y estructurada: sacar 3 datos (especialidad, fecha, motivo) de una frase corta. No requiere razonamiento profundo ni contexto extenso — un modelo grande sería sobrecosto sin mejora perceptible.
Generación de contenido con contexto RAG (Proceso B — HITL)	Claude Sonnet 4.5	\$3.00 / \$15.00	Tarea de lectura densa: interpreta varios registros de la Base de Conocimiento a la vez, mantiene el tono de marca de la clínica y redacta contenido coherente y publicable. Acá la calidad editorial justifica pagar más por token.
Procesamiento masivo diferido (ej. tandas de contenido o recordatorios)	Claude Batch API	\$1.50 / \$7.50 (50% menos que estándar)	Cuando el resultado no necesita estar listo en segundos (por ejemplo, generar contenido para todo el mes de una vez), la Batch API de Anthropic procesa en lote a mitad de precio, sin sacrificar el modelo usado.

Precios de referencia API oficiales (OpenAI y Anthropic), consultados en septiembre de 2026. Para contraste: usar GPT-4.1 (no mini) en la extracción costaría \$2.00 / \$8.00 por millón de tokens — 5 veces más caro que GPT-4.1-mini para una tarea que no necesita esa capacidad adicional.

3. Ahorro estimado a la escala actual del proyecto

Estimación ilustrativa basada en un volumen bajo, propio de la etapa de prueba del proyecto (no es el volumen real de producción de la clínica).

Escenario	Volumen mensual estimado	Costo con el modelo elegido	Costo con la alternativa cara	Ahorro
Extracción de turnos (Proceso A)	200 solicitudes/mes (~300 tokens in, 50 out c/u)	\$0.04/mes (GPT-4.1-mini)	\$0.20/mes (GPT-4.1)	80% (\$0.16/mes)
Generación de contenido (Proceso B)	40 piezas/mes (~2.000 tokens in, 400 out c/u)	\$0.48/mes (Claude Sonnet, estándar)	—	No aplica ahorro: se paga a propósito por calidad editorial

Escenario	Volumen mensual estimado	Costo con el modelo elegido	Costo con la alternativa cara	Ahorro
Generación de contenido vía Batch (si se procesa en tandas mensuales)	Mismas 40 piezas/mes	\$0.24/mes (Claude Batch API)	\$0.48/mes (Claude estándar)	50% (\$0.24/mes)

Los montos absolutos son bajos porque reflejan el volumen actual de prueba del proyecto (decenas de solicitudes, no miles). Lo que importa para la matriz no es el número final sino el **criterio de asignación**: a mayor escala (por ejemplo, una clínica con 5.000 consultas/mes), el mismo criterio de "modelo barato para extracción + modelo caro solo donde hay lectura densa + Batch API para lo no urgente" escala proporcionalmente y evita un sobre costo de miles de dólares mensuales si todo corriera sobre un único modelo premium.